

# Sílabo

Malla 2021

UTEC  
Universidad  
de Ingeniería  
y Tecnología





*DEPARTAMENTO*

Departamento de Computer  
Science



*CURSO*

Deep Learning



*MALLA*

2021



*MODALIDAD*

PRESENCIAL



*CREDITOS*

4



## **REGLAS INTEGRIDAD ACADÉMICA**

Todo estudiante matriculado en una asignatura de la Universidad de Ingeniería y Tecnología tiene la obligación de conocer y cumplir las reglas de integridad académica, cuya lista a continuación es de carácter enunciativo y no limitativo, ya que el/la docente podrá dar mayores indicaciones:

1. La copia y el plagio son dos infracciones de magnitud muy grave en la Universidad de Ingeniería y Tecnología (UTEC) conforme a lo establecido en el Reglamento de Disciplina de los Estudiantes. Tienen una sanción desde 2 semestres de suspensión hasta la expulsión.
2. Si se identifica la copia o plagio en evaluaciones individuales, el/la docente puede proceder a anular la evaluación.
3. Si la evaluación es personal o grupal-individual, la interacción entre equipos o compañeros se considera copia o plagio, según corresponda. Si la evaluación calificada no indica que es grupal, se presume que es individual.
4. La copia, plagio, el engaño y cualquier forma de colaboración no autorizada no serán tolerados y serán tratados de acuerdo con las políticas y reglamentos de la UTEC, implicando consecuencias académicas y sanciones disciplinarias.
5. Aunque se alienta a los estudiantes a discutir las tareas y trabajar juntos para desarrollar una comprensión más profunda de los temas presentados en este curso, no se permite la presentación del trabajo o las ideas de otros como propios. No se permite el plagio de archivos informáticos, códigos, documentos o dibujos.
6. Si el trabajo de dos o más estudiantes es sospechosamente similar, se puede aplicar una sanción académica a todos los estudiantes, sin importar si es el estudiante que proveyó la información o es quien recibió la ayuda indebida. En ese sentido, se recomienda no proveer el desarrollo de sus evaluaciones a otros compañeros ni por motivos de orientación, dado que ello será considerado participación en copia.
7. El uso de teléfonos celulares, aplicaciones que permitan la comunicación o cualquier otro tipo de medios de interacción entre estudiantes está prohibido durante las evaluaciones o exámenes, salvo que el/la docente indique lo contrario de manera expresa. Es irrelevante la razón del uso del dispositivo.
8. En caso exista algún problema de internet durante la evaluación, comunicarse con el/la docente utilizando el protocolo establecido. No comunicarse con los compañeros dado que eso generará una presunción de copia.
9. Se prohíbe tomar prestadas calculadoras o cualquier tipo de material de otro estudiante durante una evaluación, salvo que el/la docente indique lo contrario.
10. Si el/la docente encuentra indicios de obtención indebida de información, lo que también implica no cumplir con las reglas de la evaluación, tiene la potestad de anular la prueba, advertir al estudiante y citarlo con su Director de Carrera. Si el estudiante no asiste a la citación, podrá ser reportado para proceder con el respectivo procedimiento disciplinario. Una segunda advertencia será reportada para el inicio del procedimiento disciplinario correspondiente.
11. Se recomienda al estudiante estar atento/a a los datos de su evaluación. La consignación de datos que no correspondan a su evaluación será considerado indicio concluyente de copia.



# UNIVERSIDAD DE INGENIERÍA Y TECNOLOGÍA

## SÍLABO DEL CURSO

### 1. ASIGNATURA

CS5364 – Deep Learning

### 2. DATOS GENERALES

2.1 Ciclo: NIVEL 7

2.2 Créditos: 4

2.3 Condición: Electivo de Carrera

2.4 Idioma de dictado: Español

2.5 Requisitos: CS3061 - Machine Learning

### 3. INTRODUCCIÓN AL CURSO

En el curso de Deep Learning los estudiantes estarán especializándose a mayor profundidad con temas de Inteligencia Artificial con concentración en particular en Redes Neuronales de todo tipo y con un mayor énfasis en codificación como en la parte teórica de optimización de redes. Esta clase tendrá un nivel mayor de exigencia que en la clase previa de Machine Learning.

En particular la clase será estructurada con una sesión de teoría que consta de 5 evaluaciones y una sesión de práctica que consta de 4 evaluaciones más dos exposiciones. La sesión de teoría (ver Sección 8.2) tendrá evaluaciones a modo de un primer quiz y una evaluación parcial y final. Asimismo los estudiantes tendrán dos oportunidades durante el semestre hacer presentaciones en persona de forma grupal (grupo de 2) sobre un tema de Deep Learning en el que serán corregidos por la clase y el docente, estas evaluaciones serán parte del grupo de Laboratorio/Práctica.

Asimismo, las evaluaciones de laboratorio/práctica tendrá una índole de programación competitiva aplicado a machine learning en el que los estudiantes competirán entre ellos enviando su código en tiempo real durante el tiempo de evaluación, estandarizando la prueba para todos los estudiantes y estimulando la competencia sana. Estas evaluaciones se harán de forma individual o grupal dependiendo del laboratorio y serán calificados de forma absoluta dada una rúbrica (sin curva).

El contenido específico del curso se dividirá en dos partes. La primera parte tendrá un



índole genérica de Deep Learning, pero con ejemplos puntuales acercados hacia visión por computador. En esta primera parte se abarcaran temas como redes neuronales convolucionales, redes neuronales recurrentes, el perceptrón, y modelos generativos como el GAN y el VAE. La segunda parte del curso se subdivide en varios temas frontera como NeuroAI, Aprendizaje por Refuerzo aplicado a Juegos, Carros Autónomos y Modelos de Difusión. Cabe destacar que la segunda mitad del curso los estudiantes harán grupos de a dos para sus laboratorios con el kit internacional de DuckieBot en el que deberán implementar un mini Carro Autónomo como parte de sus 2 últimos laboratorios.

#### 4. OBJETIVOS

- Sesión 1: Nivelar a todos los alumnos (que vendrán de diversas seccion de Machine Learning) con principios básicos de Redes Neuronales, y los temas fundamentales de Deep Learning como dataset, learning rate, optimizer, architecture, loss function.
- Sesión 2: Introducir principios básicos de Redes Neuronales Convolucionales entre ellas la convolución, rectificación de media onda, pooling, y el cross-entropy loss. Se verá una formulación teórico-matemática, como de implementación/programación en PyTorch.
- Sesión 3: Aprender temas avanzados de Redes Neuronales Convolucionales, entre ellas arquitecturas modernas como el VGG, ResNet, DenseNet, y estudiar algunas ventajas y similitudes de manera muy introductoria con los Transformers. Aquí también se profundizará en redes estilo U-Net que utilizan arquitecturas de deconvolución porque servirá para la Semana 4 y Semana 5. Nótese que esta semana terminará con el primer Quiz Calificado de Aprendizaje.
- Sesión 4: Introducir los modelos Generativos en el framework del GAN así como la formulación de Equilibrio de Nash y el Min-Max Optimization de la parte teórica. Se acompañará esta clase con ejemplos visuales de Conditional GANs y U-Net en el que se vea como las redes GAN pueden tanto generar data como discriminar entre clases. En esta semana se hará el primer laboratorio calificado sobre Redes Neuronales Convolucionales.
- Sesión 5: Revisitar modelos Generativos desde el framework del VAE (Variational AutoEncoder). Aquí se explicara el ELBO, y se hará la derivación matemática, y se discutirá las diferencias entre los VAE's y los GAN's y como cada formulación apareció en su debido momento en el rubro de Computer Vision y Machine Learning. Se verán tambien ejemplos de programación sobre los VAE's.
- Sesión 6: Se enseñará los principios básicos de Transformaciones de Fourier y de filtros pasa alto y pasa bajo para el procesamiento de imágenes, así como su relación al campo de Deep Learning. Adicionalmente se enseñaron temas avanzados de procesamiento de señales y compresión (como Rate-Distortion Theory) en un marco de Deep Learning. En esta semana se hará el primer laboratorio calificado sobre Redes Neuronales Convolucionales.



- Sesión 7: Presentar de forma activa nuevos temas de Deep Learning como parte simulada de una “Clase Magistral” de los estudiantes. Esto reforzará el dominio de conceptos teóricos aprendidos en la clase, así como la capacidad de aprender y exponer de forma autodidacta del alumno.
- Sesión 8: Aprender sobre la teoría de Sparse Coding. Esta semana mezclara conceptos tanto teóricos, experimentales y computacionales sobre la historia de Sparse Coding desde la Neurociencia hasta la Inteligencia Artificial moderna. Esta semana terminará con el primer examen parcial en el que vendrán todos los temas cubiertos de la clase incluyendo algunas preguntas teóricas sobre las exposiciones hechas por los alumnos/as en clase.
- Sesión 9 : Inculcar el pensamiento científico en el área de Deep Learning. En esta semana los alumnos/as tendrán una perspectiva más rica de la evolución del área de Deep Learning desde el área de NeuroAI en el que aprenderán cómo comparar las representaciones internas humano-computador, humano-humano y computador-computador.
- Sesión 10: Introducir los conceptos básicos de redes neuronales recurrentes, así como la entrada, salida, representación latente y conexiones con teoría de control y sistemas lineales. En particular se verá en esta semana el RNN simple con entrada única/múltiple como salida única/múltiple, y asimismo se estudiará el LSTM (Long Short Term Memory) también. Se estudiará el problema de vanishing/exploding gradient. Esta semana se verán temas más avanzados de Redes Neuronales tanto en teoría como en la práctica a través de lecturas e implementaciones “hands-on” en el laboratorio.
- Sesión 11: Profundizar temas de Redes Neuronales recurrentes como los modelos Seq2Seq y los Pointer Networks, así como los Transformers. Con lo aprendido en clase, y sobre sistemas secuenciales se hará el primer Duckie Bot challenge en el Laboratorio 3, que consistirá en ruteo simple y/o pruebas de visión sobre los Duckiebots.
- Sesión 12: Se enseñará temas avanzados de Reinforcement learning, como máquinas de estado pensando en el Laboratorio 4 que será el Duckiebot challenge final. Esta semana se revisará literatura en el laboratorio relevante de Reinforcement Learning aplicado a Carros Autónomos.
- Sesión 13: Introducción a los Carros Autónomos con temas como sus partes, variables de optimización (en torno a redes neuronales), reinforcement learning y fusión de sensores. Cabe resaltar que esta semana como las pasadas después del parcial los alumnos tendrán bloques de dos horas a la semana durante sus laboratorios para avanzar con su DuckieBot durante la clase.
- Sesión 14: Se hará la segunda iteración de presentaciones grupales (estilo clases magistrales) de los estudiantes en grupos de dos. Es esperado que los alumnos den presentaciones de mejor calidad (y de un temas distinto) que de la primera iteración antes del parcial.
- Sesión 15: Se continuará con la clase de Carros Autónomos y será también la semana del Examen Final donde entran todos los temas vistos en el curso. Al final de esta semana se hará el concurso de la pista de Duckie Bots lo cual será parte del Laboratorio 4.



- Sesión 16: Último tema de la clase de Deep Learning : Modelos de Difusión que por lo general se ve en Inteligencia Artificial Generativa. Esta semana terminará con el examen final en el que vienen todos los temas que se vieron en el curso.

## 5. COMPETENCIAS Y CRITERIOS DE DESEMPEÑO

### Competencias Específicas ABET - COMPUTACION

- Analizar un problema computacional complejo y aplicar principios de computación y otras disciplinas relevantes para identificar soluciones.
- Diseñar, implementar y evaluar una solución computacional para satisfacer un conjunto determinado de requerimientos computacionales en el contexto de la disciplina del programa.
- Aplicar la teoría de la ciencia de la computación y los fundamentos de desarrollo de software para producir soluciones basadas en computación. [CS]

## 6. RESULTADOS DE APRENDIZAJE

- Crear redes neuronales convolucionales (CNN) y demostrar su comprensión mediante la formulación matemática
- Crear redes neuronales generativas (GAN y VAE) y demostrar su comprensión mediante la formulación matemática
- Aplicar los principios de Advanced RL y modelos de secuencia avanzados para el procesamiento de lenguaje natural y la visión por computadora.
- Aplicar principios de percepción avanzada y teoría de control en la toma de decisiones para sistemas de conducción autónoma.
- Explorar aplicaciones modernas de Deep Learning como NeuroAI y modelos de difusión, así como saber sus principios fundamentales.

## 7. TEMAS

### 1. Fundamentos Básicos de Redes Neuronales

- 1.1. Neurona
- 1.2. Perceptrón de Capa Única y Múltiple
- 1.3. BackPropagation & Chain-Rule
- 1.4. Loss Functions (Mean Square Errors, Cross Entropy)
- 1.5. Training, Validation & Testing Data
- 1.6. Learning Rate
- 1.7. Parámetros vs Hiperparámetros
- 1.8. Revisar : Fleuret , 2023.

### 2. Redes Neuronales Convolucionales (CNN)

- 2.1. Estructura de Imágenes y/o data bidimensional para CNNs
- 2.2. Convolución
- 2.3. Rectificación de Media Onda





- 2.4. Pooling
- 2.5. DropOut
- 2.6. Optimizadores (Adam, SGD, Gradient Descent)
- 2.7. Data Augmentation
- 2.8. Robustez a Data Fuera de Distribucion y Adversarial
- 2.9. Adversarial Training

### **3. Redes Neuronales Generativas : GANs y VAEs**

- 3.1. Equilibrio de Nash en GANs
- 3.2. Formulación de Optimización de GANs y condicional GANs
- 3.3. Aplicación de GANs para Clasificación y Generación
- 3.4. Formulación Matemática del Variational AutoEncoder
- 3.5. Ejemplos prácticos de GANs y VAEs
- 3.6. Evidence Lower Bound (ELBO)
- 3.7. Representaciones latentes de Modelos Generativos

### **4. Signal Processing + Image Compression + Rate-Distortion Theory**

- 4.1. Transformación de Fourier aplicado de Imágenes
- 4.2. Filtros Pasa-Bajo y Pasa-Alto
- 4.3. Pirámides de Imágenes (Gaussian + Laplacian Pyramid)
- 4.4. Aliasing
- 4.5. Ilusiones Opticas
- 4.6. Compression Lossy : JPEG
- 4.7. Compression LossLess : PNG
- 4.8. Uso de Redes Neuronales para compresión de Imágenes
- 4.9. Principios básicos de Rate-Distortion Theory
- 4.10. Optimización Perceptual (SSIM y Metamerismo)

### **5. Sparse Coding (Theory + Code + Neuroscience)**

- 5.1. Estudio de paper clásico de Olshausen y Field (1996)
- 5.2. Revisión de estudios de neurofisiología de Hubel y Wiesel (1959)
- 5.3. Modelamiento matemático de Sparse Coding
- 5.4. Implicaciones del Sparsity Constraint en Redes Neuronales
- 5.5. Interpretación cualitativa y metafísica de basis functions

### **6. NeuroAI: Experimental Design + Representational Similarity Analysis**

- 6.1. Diseño experimental básico: experimento principal y de control, definición de hipótesis nula.
- 6.2. Fundamentos de Signal Detection Theory y Psicofísica.
- 6.3. Interpretación de diseño experimental teórica, computacional y experimental.
- 6.4. Representation Similarity Analysis y CKA (Centered Kernel Alignment). Principios básicos de comparación de representaciones humano-humano, humano-maquina, maquina-maquina. [Kriegeskorte, 2008]]





6.5. Robustez y eficiencia de Sistemas NeuroAI. Ventajas y desventajas de sistemas NeuroAI.

6.6. Revisar : Harrington & Deza, 2022 ; Berrios & Deza, 2022.

## **7. Advanced RL : Large Language Models, Games, Protein Folding**

7.1. Ecuaciones de Bellman para Reinforcement Learning

7.2. Revisión de modelos de Markov y Markovian Assumption

7.3. Reinforcement Learning with Human Feedback (RLHF)

7.4. Entrenamiento de sistemas de Reinforcement Learning y coste computacional.

7.5. Declaración y definición de Agente, Ambiente, Acción, Estado y Recompensa.

7.6. Direct Preference Optimization vs Proximal Policy Optimization

7.7. Revisar : Naturalistic Reinforcement Learning (Wise, 2023); muZero (DeepMind, 2020)

## **8. Advanced Sequence Models: RNNs, LSTMs, Seq2Seq, Transformers**

8.1. Vanishing & Exploding Gradient

8.2. Variaciones de RNNs múltiples entradas y múltiples salidas como entrada única y salida única.

8.3. LSTMs y descripción de cada bloque en la célula y función

8.4. Modelos Seq2Seq y variantes como Pointer Networks que vienen de RNNs y LSTMs

8.5. Principios Básicos de Transformers

8.6. Aplicación de RNNs, LSTMs y modelos Seq2Seq y Transformers para Procesamiento Natural de Lenguaje y Visión por Computador.

8.7. Revisar: Pointer Networks de Vinyals, 2015

## **9. Autonomous Driving**

9.1. Variables de Optimización para Carros Autónomos

9.2. Odometría, Optical Flow, Vision por Computadora (Object Detection + Object Classification)

9.3. Sensor Fusion : LIDAR, RADAR, Ultrasonido y Cámara. Mecanismos de Redundancia y FailSafes.

9.4. Integración de Reinforcement Learning para Carros Autónomos

9.5. Event-Based Programming y Máquinas de Estados (State Machines)

9.6. Percepción Avanzadas, toma de decisiones y principios básicos de la teoría de control.

9.7. Mecanismos de entrenamiento con Digital Twins.

## **10. Diffusion Models**

10.1. Introducción a los modelos de Difusión

10.2. Formulación Matemática de modelos de Difusión (Forward y Backward Pass)

10.3. Aplicaciones modernas de modelos de Difusión

10.4. Asesoramiento cualitativo y cuantitativo de modelos de difusión.

10.5. Revisar: Jascha Sohl-Dickstein, 2015.



## **8. PLAN DE TRABAJO**

### **8.2 Sesiones de teoría**

En cada sesión de teoría el docente empleará una mezcla de herramientas multimedia (proyector + computadora), así como la pizarra para de forma analógica profundizar el tema que se irá aprendiendo durante la clase. Como la clase es pequeña (24 alumnos por clase), también se tendrá un enfoque de aprendizaje activo en el que los alumnos/as podrán hacer sus preguntas durante la clase y también serán sacados a la pizarra de forma dinámica para explorar el nivel de absorción de conocimiento durante cada sesión.

El Docente será el único encargado de dar las cátedras durante las horas de teoría, salvo las dos semanas en que los estudiantes deben hacer presentaciones teóricas sobre temas a abordar en la clase. Estas sesiones serán calificadas tanto por el docente como los alumnos.

### **8.3 Sesiones de práctica (laboratorio o taller)**

Las sesiones de Laboratorio o Taller tendrán una índole de Hands-On en la que se revisaran papers en las sesiones que no son calificadas promoviendo el aprendizaje grupal y activo, así como otras sesiones hands-on de programación en las que se implementarán modelos de redes neuronales.

Adicionalmente, para la parte de evaluación del laboratorio o taller, habrán 4 laboratorios calificados in-situ en que los estudiantes deberán programar una solución que requiere de conocimiento expuesto en clase de redes neuronales. Los laboratorios tendrán una índole competitiva en la que los estudiantes enviarán sus soluciones ya sea en una plataforma virtual (como Kaggle), o una plataforma física (el uso de los DuckieBots en la segunda mitad del semestre). Cabe resaltar que si bien los laboratorios serán competitivos, las notas no serán con curva y serán absolutas dada una rúbrica por lo general pre-determinada por el profesor/docente antes del laboratorio.

En algunas de las sesiones de Práctica y Teoría también se contará con exposiciones grupales sobre temas avanzados de Deep Learning para reforzar la fluidez de exposición así como dominio del conocimiento de los estudiantes. Asimismo esta nota será grupal para promover el aprendizaje en equipo sobre temas avanzados de Deep Learning lo cuales serán útil para fines académicos, industriales y de start-ups.



## 9. SISTEMA DE EVALUACIÓN

El curso consta de los siguientes espacios de evaluación:

Evaluación	Teoría
	<b>TEORÍA 40%</b> <ul style="list-style-type: none"><li>•Evaluación Continua1 (C) (10%)</li><li>•Examen Parcial (TA2) (10%)</li><li>•Examen Final (TA3) (10%)</li></ul> <b>LABORATORIO (60%)</b> <ul style="list-style-type: none"><li>•Laboratorio (L1) (10%)</li><li>•Laboratorio (L2) (10%)</li><li>•Laboratorio (L3) (10%)</li><li>•Laboratorio (L4) (10%)</li><li>•Exposición 1 (O1) (15 %)</li><li>•Exposición 2 (O2) (15 %)</li></ul> <b>Nota:</b> La ponderación de la evaluación se hará si ambas partes están aprobadas.
	<b>100%</b>

## 10. REFERENCIAS BIBLIOGRÁFICAS

- 1.Fleuret, F. (2023). The Little Book of Deep Learning. A lovely concise introduction.
- 2.Kreiman, G. (2021). Biological and computer vision. Cambridge University Press.
- 3.Goodfellow, I., Bengio, Y., & Courville, A. (2016). Deep learning. MIT press.
- 4.Zhang, A., Lipton, Z. C., Li, M., & Smola, A. J. (2023). Dive into deep learning. Cambridge University Press.
- 5.Bishop, C. M., & Bishop, H. (2023). The Deep Learning Revolution. In Deep Learning: Foundations and Concepts (pp. 1-22). Cham: Springer International Publishing.

